ESCUELA POLITÉCNICA NACIONAL

Facultad de Ingeniería de Sistemas · Carrera de Ciencia de Datos e Inteligencia Artificial

INFORME DE PRÁCTICA N.º 1

Consolidación de reportes de ventas (CSV, JSON y Excel)

Tópico 1 del PEA · Asignatura IDSD422 — Estadística y Programación para Ciencia de Datos I

Estudiante(s)	Tiupul Irua, Jhon Jairo — usuario de GitHub: jhont-ml
Docente	Ing. Christian Suárez, M.Sc.
Período académico	2026-B
Fecha de entrega	19/10/2026
Repositorio (fork)	https://github.com/jhont-ml/IDSD422-lab1-lectura-datos.git

1. Introducción

RetailAndina S.A. necesita presentar en la reunión de gerencia el reporte de ventas de la semana 39 de sus cinco sucursales. Este reporte no llega en un solo archivo: el ERP de las sucursales lo exporta en CSV, la API del programa de fidelización lo envía en JSON y el área de finanzas lo consolida en Excel. Como son tres sistemas independientes, antes de usar la información para tomar decisiones hay que comprobar que los tres archivos dicen lo mismo.

Los datos corresponden a cinco sucursales de la Sierra y la Costa, con cuatro variables: sucursal, región, ventas y clientes. En esta práctica leí los tres archivos con Python y con R, comparé sus dimensiones y tipos de datos y calculé los indicadores que pide la gerencia: venta promedio, ticket promedio, sucursal con mayor y menor venta y ventas por región.

2. Objetivos

Objetivo general. Analizar el reporte de ventas de la semana 39 de RetailAndina S.A., disponible en CSV, JSON y Excel, usando Python y R, para verificar su consistencia y calcular los indicadores que necesita la gerencia.

Objetivos específicos.

1. Leer ventas.csv, ventas.json y ventas.xlsx en Python y en R con la librería adecuada para cada formato.
2. Verificar que las dimensiones y los tipos de datos coinciden en los tres formatos y en ambos lenguajes.
3. Calcular la venta promedio, el ticket promedio, la sucursal con mayor y menor venta y la región con mayor venta.
4. Comparar los resultados obtenidos en Python y en R y reportar las diferencias.

3. Desarrollo de la práctica

Hice un fork del repositorio del docente y lo cloné en mi computadora. Trabajé Python en Google Colab y R en Posit Cloud, con los archivos dentro de la carpeta data/. El código clave comentado está en el Anexo A.

3.1 Lectura de los tres formatos en Python - Google Colab

Para cada formato usé la función de pandas correspondiente (pandas development team, 2026): read_csv() para el CSV, read_excel() con sheet_name="ventas" para el Excel y, para el JSON, json.load() y luego json_normalize(), porque json.load() devuelve una lista de diccionarios que hay que convertir en tabla. En los tres casos imprimí head(), shape y dtypes.

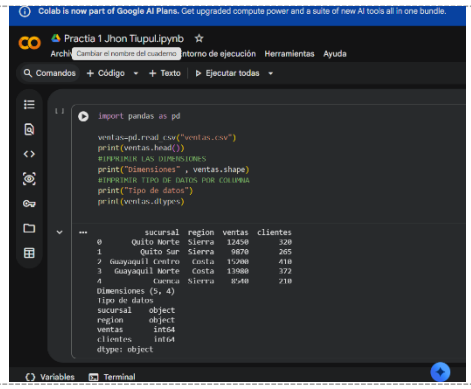


Figura 1. Lectura del CSV en Python con pd.read_csv(): shape (5, 4) y tipos object e int64.

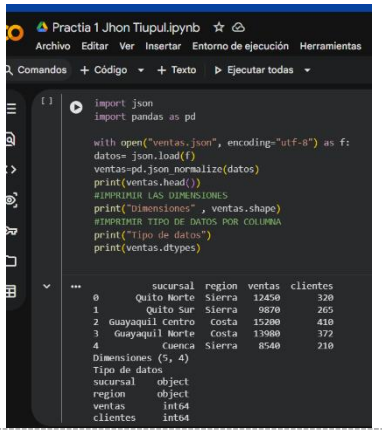


Figura 2. Lectura del JSON en Python con json.load() y pd.json_normalize(): shape (5, 4).

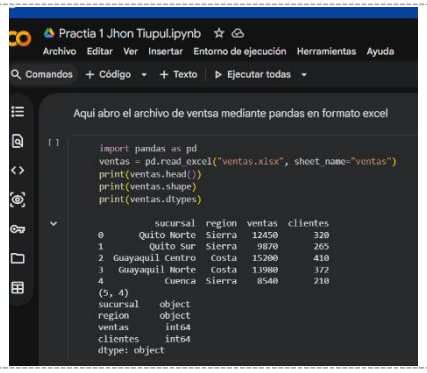


Figura 3. Lectura de la hoja "ventas" del Excel con pd.read_excel(): shape (5, 4).

Los tres formatos dieron el mismo DataFrame de 5 filas y 4 columnas: sucursal y region como object (texto) y ventas y clientes como int64 (enteros). Por lo tanto, la información es la misma y los números se pueden usar directamente.

3.2 Cálculo de indicadores en Python

Con el CSV creé la columna ticket = ventas / clientes, que indica cuánto gasta en promedio cada cliente en cada sucursal. Para el ticket general dividí el total de ventas para el total de clientes, en lugar de promediar los cinco tickets, así cada sucursal pesa según los clientes que atiende (con el promedio simple saldría $38,29 en vez de $38,07).

.

```
print(ventas.head())

print(ventas["ventas"].max())
print("sucursal con mayor venta:", ventas.loc[ventas["ventas"].idxmax(), "sucursal"])

print("sucursal con menor venta:", ventas.loc[ventas["ventas"].idxmin(), "sucursal"])
```

```
          sucursal  region  ventas  clientes     ticket
0       Quito Norte  Sierra   12450       320  38.906250
1        Quito Sur  Sierra    9870       265  37.245283
2  Guayaquil Centro   Costa   15200       410  37.073171
3   Guayaquil Norte   Costa   13980       372  37.580645
4           Cuenca  Sierra    8540       210  40.666667
15200
sucursal con mayor venta: Guayaquil Centro
sucursal con menor venta: Cuenca
```

Tabla 1. Ventas, clientes y ticket por sucursal, semana 39 (salida de la Figura 4).

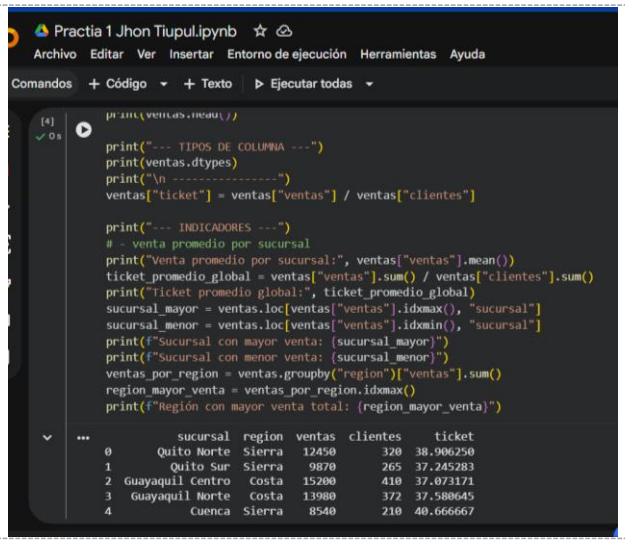


Figura 4. Cálculo del ticket y de los indicadores en Python.

La venta promedio por sucursal fue de $12 008 y el ticket general de $38,07. Guayaquil Centro tuvo la mayor venta ($15 200) y Cuenca la menor ($8 540). Por región, la Sierra sumó $30 860 y la Costa $29 180. Lo interesante es que Cuenca, aunque vende menos, tiene el ticket más alto ($40,67), mientras que Guayaquil Centro tiene el más bajo ($37,07): vende más porque atiende más clientes (410), no porque cada uno gaste más.

3.3 Lectura de los formatos en R - Posit Cloud

En R usé read_csv() de readr para el CSV (Wickham et al., 2024), fromJSON() de jsonlite para el JSON (Ooms, 2014) y read_excel() de readxl con sheet = "ventas" para el Excel (Wickham y Bryan, 2023), y revisé cada uno con dim() y str(). El paquete jsonlite no estaba instalado, así que lo instalé con install.packages("jsonlite"). A diferencia de Python, fromJSON() ya devuelve un data.frame, por lo que no tuve que aplanar nada.

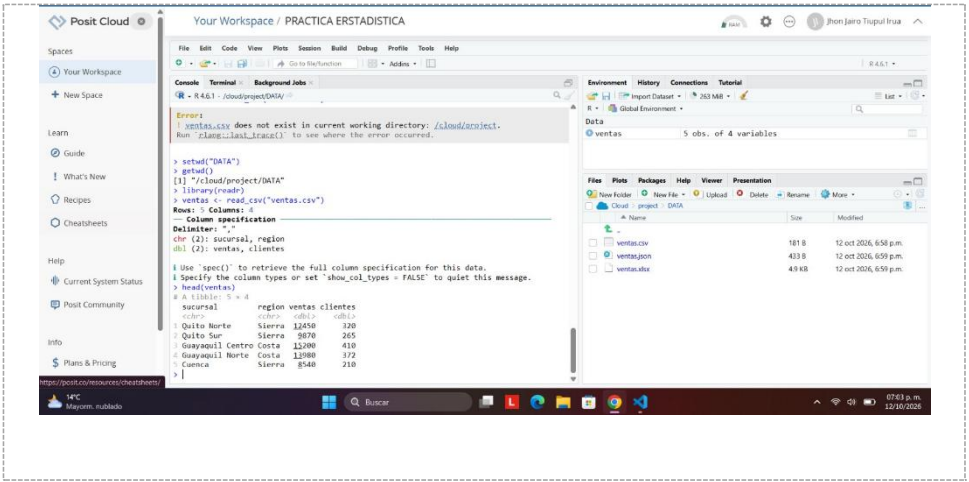


Figura 5. Lectura de ventas.csv y ventas.xlsx en R con read_csv() y read_excel(): dimensión 5 × 4.

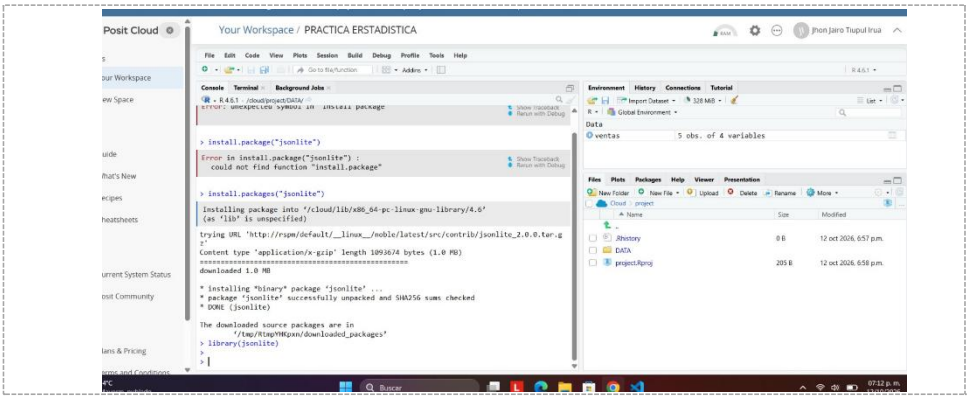


Figura 6. Instalación de jsonlite y lectura de ventas.json en R con fromJSON(): dimensión 5 × 4.

Los tres archivos dieron 5 × 4 también en R. La única diferencia está en el tipo numérico: readr y readxl leen ventas y clientes como dbl (decimal), jsonlite como int y pandas como int64. Los valores son los mismos, así que no afecta los cálculos.

3.4 Indicadores en R y comparación con Python

Repetí los cálculos en R con el mismo criterio que en Python y comparé los resultados en la Tabla 2.

Indicador	Python	R
Venta promedio por sucursal	12008.0	12008
Ticket promedio general	38.0723	38.0723
Sucursal con mayor venta	Guayaquil Centro	Guayaquil Centro
Sucursal con menor venta	Cuenca	Cuenca
Región con mayor venta	Sierra	Sierra

Tabla 2. Comparación de los indicadores obtenidos en Python y en R.

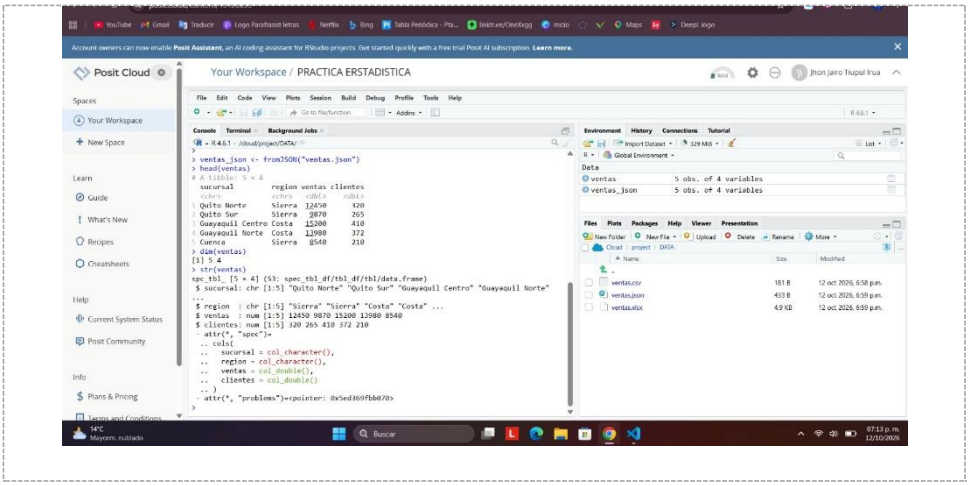


Figura 7. Cálculo del ticket y de los indicadores en R: mismos resultados que en Python.

Los cinco indicadores coinciden en ambos lenguajes. La única diferencia es la forma de mostrar los números (Python imprime 12008.0 y R 12008), lo que no cambia el resultado.

4. ¿Qué aprendí con esta práctica?

Aprendí que antes de calcular cualquier indicador hay que revisar cómo se leyó el archivo: sus dimensiones y el tipo de cada columna. También entendí que cada formato necesita su propia forma de lectura: el CSV ya es una tabla, el JSON llega como una lista de registros que en Python hay que aplanar, y el Excel puede tener varias hojas, por eso se indica cuál leer. Otra cosa que aprendí es que el ticket general debe calcularse con los totales y no promediando los tickets de cada sucursal.

Lo más difícil fue subir los archivos de ventas al Google Colab, al momento de ejecutar el código tuve la falencia de subirlo en otro directorio. Lo resolví cambiado la ruta del directorio donde subí los documentos así pudiendo concluir con la ejecución del código. La próxima me aseguraría de saber la ubicación de los archivos para no tener problemas de ejecución además a la vez instalaría todas las librerías antes de empezar y trabajaría desde el inicio con rutas relativas a la carpeta del repositorio.

5. Conclusiones

1. Los tres formatos contienen la misma información: en Python y en R se obtuvieron 5 filas y 4 columnas, con sucursal y región como texto y ventas y clientes como numéricos. La única diferencia fue el nombre del tipo numérico (int64, int o dbl), sin cambio en los valores.
2. La semana 39 cerró con $60 040 en ventas, una venta promedio de $12 008 por sucursal y un ticket general de $38,07. Guayaquil Centro fue la sucursal con mayor venta ($15 200) y Cuenca la de menor ($8 540); la Sierra vendió $30 860 frente a $29 180 de la Costa.
3. Cuenca tiene el ticket más alto ($40,67) aunque es la que menos vende, y Guayaquil Centro el más bajo ($37,07) aunque es la que más vende. Python y R dieron los mismos resultados.

A la gerencia le diría que los tres reportes son equivalentes y se pueden usar con confianza. Con solo cinco sucursales y una semana de datos, este análisis describe únicamente la semana 39 y no permite proyectar ventas futuras.

6. Bibliografía y declaración de uso de IA

Ooms, J. (2014). *The jsonlite package: A practical and consistent mapping between JSON data and R objects*. arXiv. https://arxiv.org/abs/1403.2805

pandas development team. (2026). *pandas documentation: read_csv, read_excel y json_normalize*. https://pandas.pydata.org/docs/reference/io.html

Wickham, H. y Bryan, J. (2023). *readxl: Read Excel files* [Paquete de R]. https://CRAN.R-project.org/package=readxl

Wickham, H., Hester, J. y Bryan, J. (2024). *readr: Read rectangular text data* [Paquete de R]. https://CRAN.R-project.org/package=readr

Declaración de uso de IA: utilicé Claude (Anthropic) como apoyo para organizar la estructura del informe y revisar la redacción. La redacción del documento, faltas ortográficas y verificar la concordancia u coherencia en el documento.

Anexo A. Código clave comentado

R (Posit Cloud):

```
> library(readr); library(jsonlite); library(readxl)
> df_csv  <- read_csv("ventas.csv")
Rows: 5 Columns: 4
── Column specification ────────────────────────────────────────────────────────
Delimiter: ","
chr (2): sucursal, region
dbl (2): ventas, clientes

ℹ Use `spec()` to retrieve the full column specification for this data.
ℹ Specify the column types or set `show_col_types = FALSE` to quiet this message.
> df_json <- fromJSON("ventas.json")                    # ya devuelve data.frame
> df_xlsx <- read_excel("ventas.xlsx", sheet = "ventas")
> dim(df_csv); dim(df_json); dim(df_xlsx)                    # dimensiones
[1] 5 4
[1] 5 4
[1] 5 4
>
> df_csv$ticket <- df_csv$ventas / df_csv$clientes            # ticket por sucursal
> ticket_gen <- sum(df_csv$ventas) / sum(df_csv$clientes)     # ticket general
> df_csv$sucursal[which.max(df_csv$ventas)]                   # which.min para la menor
[1] "Guayaquil Centro"
> aggregate(ventas ~ region, data = df_csv, FUN = sum)        # ventas por region
  region ventas
1  Costa  29180
2 Sierra  30860
```

Python (Google Colab):

```
[7]
✓ 0s
import pandas as pd, json
df_csv  = pd.read_csv("ventas.csv")                    # CSV directo
with open("ventas.json", encoding="utf-8") as f:
    df_json = pd.json_normalize(json.load(f))               # aplano la lista de diccionarios
df_xlsx = pd.read_excel("ventas.xlsx", sheet_name="ventas")  # indico la hoja
print(df_csv.shape, df_json.shape, df_xlsx.shape)           # dimensiones

df_csv["ticket"] = df_csv["ventas"] / df_csv["clientes"]     # ticket por sucursal
ticket_gen = df_csv["ventas"].sum() / df_csv["clientes"].sum()   # ticket general con totales
mayor = df_csv.loc[df_csv["ventas"].idxmax(), "sucursal"]   # idxmin para la menor
reg = df_csv.groupby("region")["ventas"].sum()              # ventas por region

(5, 4) (5, 4) (5, 4)
```